

Sujet de Stage

Augmentation de Données Guidée par XAI via Modèles Génératifs
pour la Classification Déséquilibrée de Lésions Cutanées en
Dermoscopie

*XAI-Guided Data Augmentation via Generative Models for Imbalanced Skin Lesion
Classification from Dermoscopy Images*

Mots-clés — Skin Lesion Classification · Class Imbalance · DINOv2 · GAN · Stable Diffusion · LoRA ·
Explainable AI · Doctor-in-the-Loop · ISIC · Dermoscopy

Durée : 2 mois

Table des matières

1. Contexte et Problématique	3
2. Pipeline Proposé	4
2.1 Backbone de Classification — DINOv2	4
2.2 Stratégie d'Augmentation Progressive	4
2.3 Porte de Qualité XAI Automatisée	5
2.4 Intégration Clinique Asynchrone	5
3. Protocole Expérimental	7
4. Planning de Travail	8
5. Livrables Attendus	9
6. Perspectives	10
7. Récapitulatif	11

1. Contexte et Problématique

La classification automatique des lésions cutanées à partir d'images de dermoscopie constitue une application clinique d'importance majeure, où les modèles d'apprentissage profond se heurtent à une contrainte fondamentale : la distribution statistique extrêmement déséquilibrée des jeux de données réels.

Dans la base de référence ISIC 2019, les classes dominantes — telles que les naevus mélanocytaires (plus de 12 000 échantillons) — coexistent avec des classes cliniquement critiques mais sous-représentées : les lésions vasculaires (VASC, $n = 253$) et les dermatofibromes (DF, $n = 239$) totalisent moins de 300 images chacune, générant un ratio de déséquilibre atteignant 54 : 1. Ce biais structurel conduit les classifieurs à favoriser systématiquement les classes majoritaires, dégradant ainsi la sensibilité précisément dans les cas où la précision diagnostique est la plus cruciale.

Les stratégies classiques de remédiation — sur-échantillonnage aléatoire, SMOTE, fonctions de coût pondérées — corrigent le déséquilibre statistique sans toutefois enrichir la diversité visuelle de la distribution d'entraînement. Les approches génératives naïves (GANs inconditionnels, modèles de diffusion génériques) produisent certes des images visuellement plausibles, mais n'offrent aucune garantie de cohérence clinique : une lésion synthétique peut paraître réaliste tout en encodant des structures dermoscopiques erronées pour la classe attribuée, corrompant ainsi silencieusement le jeu d'entraînement.

Le présent stage propose un pipeline d'augmentation générative progressif dans lequel les images synthétiques des classes minoritaires sont produites par des architectures génératives de complexité croissante, filtrées par une porte de qualité XAI automatisée, et soumises à une révision asynchrone par un dermatologue — sans blocage du processus d'entraînement.

2. Pipeline Proposé

2.1 Backbone de Classification — DINOv2

DINOv2 (ViT-B/14) sert d'extracteur de caractéristiques partagé à l'ensemble des étapes du pipeline. Une tête MLP légère est entraînée au-dessus de l'encodeur gelé ou légèrement affiné. DINOv2 est retenu pour la capacité de ses cartes d'attention multi-têtes à produire une cartographie de saillance spatialement ancée au niveau patch, sans coût additionnel. Cette cartographie sert simultanément de signal XAI pour le filtrage automatisé et d'explication visuelle présentée au dermatologue lors de la révision asynchrone.

2.2 Stratégie d'Augmentation Générative Progressive

Plutôt que de s'engager sur une architecture générative unique dès le départ, le pipeline adopte une approche progressive : un modèle simple est entraîné en premier, ses sorties sont évaluées, et un modèle plus expressif est introduit si la qualité ou la diversité s'avèrent insuffisantes. Cette conception constitue un mécanisme naturel de gestion des risques au sein de la contrainte temporelle de deux mois.

Étape A — GAN Conditionnel (modèle génératif de référence)

Un DCGAN ou StyleGAN2-ADA léger est affiné indépendamment sur chaque classe minoritaire. StyleGAN2-ADA est spécifiquement conçu pour les petits jeux de données : son augmentation adaptative du discriminateur stabilise l'entraînement avec seulement 200 images, ce qui le rend particulièrement adapté aux classes minoritaires d'ISIC. Chaque générateur conditionnel est entraîné sur 500 à 1 000 itérations, produisant un premier lot de candidats synthétiques en 3 à 6 heures par classe sur GPU unique.

Les sorties du GAN sont évaluées par le score FID calculé sur des échantillons réels de validation de la même classe. Si le FID dépasse un seuil de qualité prédéfini, ou si la porte XAI rejette plus de 60 % des sorties du GAN, l'Étape B est activée.

Étape B — Stable Diffusion 1.5 + LoRA (modèle génératif expressif)

Un affinage LoRA de Stable Diffusion 1.5 est réalisé sur chaque classe minoritaire, en conditionnant la génération sur un prompt textuel associé à l'étiquette de classe. LoRA n'adapte qu'environ 0,5 % des paramètres du modèle (matrices de rang faible injectées dans les couches d'attention de l'U-Net), permettant une adaptation spécifique à chaque classe en 2 à 4 heures sur GPU unique tout en préservant les forts priors visuels du modèle de base. SD 1.5 + LoRA produit typiquement une fidélité visuelle supérieure et une diversité morphologique accrue par rapport au GAN de référence, au prix d'un temps de génération plus long par image.

Les deux étapes génératives ne sont pas mutuellement exclusives : dans le jeu de données augmenté final, les sorties GAN et SD+LoRA ayant toutes deux passé la porte XAI sont agrégées, offrant au classifieur l'accès à la distribution synthétique validée la plus large.

2.3 Porte de Qualité XAI Automatisée

Tous les échantillons synthétiques — quelle que soit l'étape générative — traversent un filtre de qualité automatisé avant toute utilisation en entraînement ou révision clinique :

- Extraction de la carte d'attention DINOv2 de l'image synthétique.
- Calcul d'un profil d'attention de référence pour la classe cible, défini comme la carte d'attention moyenne sur l'ensemble des échantillons réels d'entraînement de cette classe.

- Calcul de la similarité cosinus entre la carte d'attention de l'image synthétique et le profil de référence de la classe.
- Rejet automatique des images dont la similarité est inférieure à un seuil initial de 0,5 (ajusté sur un ensemble de validation).

Cette porte élimine les échantillons structurellement incohérents — lésions absentes ou mal localisées, textures collapsées, sorties morphologiquement implausibles — avant qu'ils n'atteignent l'entraînement ou la révision clinique, maximisant ainsi à la fois la qualité des données d'entraînement et l'efficacité de la révision dermatologique.

2.4 Intégration Clinique Asynchrone

La révision clinique est explicitement conçue comme un processus parallèle et non bloquant. Le pipeline d'entraînement n'attend pas la validation médicale : le classifieur est entraîné immédiatement sur les échantillons synthétiques validés par la porte XAI, et la rétroaction clinique est collectée de manière asynchrone via une interface de révision légère.

Interface de révision dermatologique

Pour chaque image candidate, l'interface présente : (i) l'image synthétique en résolution complète ; (ii) la carte d'attention DINOv2 en surimpression, mettant en évidence les régions saillantes pour la classe assignée ; (iii) trois images réelles plus proches voisins de la même classe (récupérées par similarité de caractéristiques DINOv2) comme panneau de référence visuelle.

Pour chaque candidat, le dermatologue fournit une réponse unique à trois voies : Valider, Rejeter, ou Signaler pour discussion. Chaque session de révision couvre un lot de 50 images et est conçue pour durer moins de 30 minutes.

Utilisation de la rétroaction clinique

Les étiquettes cliniques (validé / rejeté / signalé) sont enregistrées comme métadonnées attachées à chaque échantillon synthétique. Elles sont exploitées de trois manières complémentaires — aucune ne bloquant l'entraînement :

- Une analyse post-hoc mesurant la corrélation entre le statut de validation clinique et le gain de classification par classe : les échantillons cliniquement validés contribuent-ils davantage au rappel des classes minoritaires que les échantillons filtrés uniquement par la porte XAI ?
- Une expérience d'entraînement affinée où un second classifieur est entraîné exclusivement sur les échantillons synthétiques cliniquement validés, afin de quantifier le bénéfice marginal du filtrage clinique par rapport au filtrage automatisé.
- Une métrique de qualité des modèles génératifs : le taux de rejet clinique par étape générative (GAN vs. SD+LoRA) fournit une comparaison ancrée sur l'humain des deux architectures, au-delà du FID.

L’interface est implémentée comme une application Gradio — aucune installation requise, opérable depuis tout navigateur — avec journalisation des sessions dans une base de données SQLite légère.

3. Protocole Expérimental

Jeu de données

ISIC 2019 — 8 classes de lésions cutanées, environ 25 000 images de dermoscopie, publiquement disponible, avec masques de segmentation des lésions pour l’évaluation de localisation XAI et des splits train/val/test officiels pour un benchmarking reproductible.

Classes minoritaires cibles

Lésion vasculaire (VASC, n = 253), Dermatofibroma (DF, n = 239), Kératose actinique (AK, n = 867) — les trois classes les plus sous-représentées, et les plus adaptées à un affinage LoRA compte tenu de leurs effectifs.

Configurations comparées

ID	Configuration
B1	DINOv2 + MLP, sans augmentation, perte pondérée par classe
B2	DINOv2 + MLP, augmentation standard, perte pondérée par classe
B3	DINOv2 + MLP, SMOTE dans l’espace de caractéristiques DINOv2
B4	DINOv2 + MLP, synthèse GAN + porte XAI
B5	DINOv2 + MLP, synthèse SD 1.5 + LoRA + porte XAI
Proposé	DINOv2 + MLP, GAN + SD 1.5 + LoRA agrégés + porte XAI

Métriques d’évaluation

AUC-ROC par classe, macro F1, sensibilité et spécificité par classe sur les classes minoritaires, IoU de localisation de saillance (cartes d’attention DINOv2 vs. masques de lésion ISIC), FID par étape générative, et taux de rejet clinique par étape générative.

4. Planning de Travail

Semaine	Tâches
1	Configuration de l'environnement · Chargement ISIC 2019 et analyse du déséquilibre · Baselines DINOv2 gelé (B1, B2)
2	Affinage StyleGAN2-ADA sur VASC, DF, AK · Évaluation FID · Implémentation de la porte XAI
3	Affinage SD 1.5 + LoRA sur les 3 classes · Comparaison FID et taux de rejet (GAN vs. LoRA)
4	Construction du jeu augmenté (agrégation GAN + LoRA validés) · Développement de l'interface Gradio · Première session de révision clinique
5	Entraînement des classifieurs (B1→B5 + proposé) · Évaluation comparative complète
6	Analyse clinique post-hoc · Expérience B5-clinical · Analyse détaillée par classe
7	Études d'ablation · Sensibilité au seuil de la porte XAI · Analyse de contribution GAN vs. LoRA
8	Rédaction du rapport · Figures et tableaux de résultats · Présentation du stage

5. Livrables Attendus

- Pipeline d'entraînement et d'évaluation reproductible (PyTorch, Hugging Face Diffusers, Albumentations).
- Points de contrôle (checkpoints) affinés de StyleGAN2-ADA et de SD 1.5 + LoRA pour les classes VASC, DF et AK.
- Application Gradio de révision clinique avec journalisation des sessions, réutilisable pour de futurs jeux de données.
- Tableaux de performance par classe comparant l'ensemble des méthodes de référence et la méthode proposée.
- Comparaison quantitative GAN vs. SD+LoRA : FID, taux de rejet de la porte XAI, taux de rejet clinique, et impact sur la classification en aval.
- Rapport de stage structuré comme un article de recherche court.

6. Perspectives

Conditionnement textuel par BiomedCLIP

Remplacer le prompt d'étiquette de classe dans SD+LoRA par des embeddings textuels cliniques BiomedCLIP encodant des descripteurs dermoscopiques fins, afin de réduire le taux de rejet de la porte XAI en améliorant la précision sémantique de la génération.

Conditionnement spatial par MedSAM

Utiliser les masques de segmentation de lésions MedSAM comme conditionnement d'inpainting pour le modèle de diffusion, contraignant la pathologie synthétique à des frontières anatomiquement réalistes.

Apprentissage contrastif supervisé

Ajouter une perte contrastive supervisée sur DINOv2, incorporant les échantillons synthétiques validés par XAI comme positifs contrastifs avec pondération inverse de fréquence.

Classifieur de rejet clinique

Entraîner un classifieur léger sur les étiquettes cliniques collectées pour prédire l'acceptation dermatologique, en vue d'automatiser ultérieurement l'étape de révision clinique pour les scénarios de génération à haut volume.

Extension aux radiographies thoraciques

Généraliser le pipeline au jeu de données NIH ChestX-ray14 avec RayDINO comme backbone spécialisé au domaine.

7. Récapitulatif

Composante	Choix	Justification
Backbone + XAI	DINOv2 ViT-B/14	Fonctions riches + saillance par attention sans coût additionnel
Modèle génératif A	StyleGAN2-ADA	Stable sur petites données · entraînement rapide · bonne référence
Modèle génératif B	SD 1.5 + LoRA	Haute fidélité · conditionnement textuel · 2–4h/classe

Composante	Choix	Justification
Filtre automatisé	Porte XAI (similarité cosinus)	Élimine les échecs avant entraînement et révision
Révision clinique	Interface Gradio · asynchrone · non bloquante	Boucle de rétroaction parallèle, sans dépendance critique
Utilisation clinique	Analyse post-hoc + expérience affinée	Enrichit l'évaluation sans créer de goulot d'étranglement
Classes cibles	VASC · DF · AK (3 plus déséquilibrées)	Périmètre maîtrisable en 2 mois

Sujet de Stage

XAI-Guided Data Augmentation

Durée : 2 mois · ISIC 2019 · Dermoscopie